



DBLSTM-WS

汇报人：陈冉

CITE: "A novel wavelet sequence based on deep bidirectional LSTM network model for ECG signal classification"

主要内容：提出了一种基于双向LSTM网络的小波序列模型DBLSTM-WS，用于对ECG信号进行分类。设计了一个基于小波变换的层来生成ECG信号序列。ECG信号被分解为该层中不同尺度的频率子带。这些子带用作LSTM网络输入的序列。同时也用单向（ULSTM）和双向（BLSTM）结构在内的网络模型进行性能比较。

数据来源：对MIT-BIH心律失常数据库中的五种不同类型的心跳进行了实验研究。这五种类型分别是正常窦性心律（NSR）、室性早搏（VPC）、起搏搏动（PB）、左束支传导阻滞（LBBB）和右束支传导阻滞（RBBB）。

实验结果：DBLSTM-WS模型具有高达99.39%的高识别性能。研究表明，研究中提出的基于小波的层显著提高了传统网络的识别性能。这种提出的网络结构是一种可以应用于类似信号处理问题的重要方法。

Content



Ch.1 LSTM Model

Ch.2 About The Paper

Ch.3 Experimental Result

Ch.4 Summary

Ch.1 LSTM

RNN Model

“Harry Potter and Herminoe Granger invented a new spell..”

现在想要建立一个能够自动识别句中人名位置的模型。

输入的每个单词都对应一个输出值，同时这个能够表明输入的单词是否是人名的一部分。


Ch.1 LSTM

RNN Model

$$a^{<1>} = g_1(W_{aa}a^{<0>} + W_{ax}x^{<1>} + b_a)$$


$$\hat{y}^{<1>} = g_2(W_{ya}a^{<1>} + b_y)$$

“Harry Potter and Hermoine Granger invented a new spell..”



Ch.1 LSTM

RNN Model




Teddy Roose was a great President.

Teddy bears are on sale!

Ch.1 LSTM

LSTM Blocks



Teddy Roosevelt was a great President.

Teddy bears are on sale!

Ch.1 LSTM

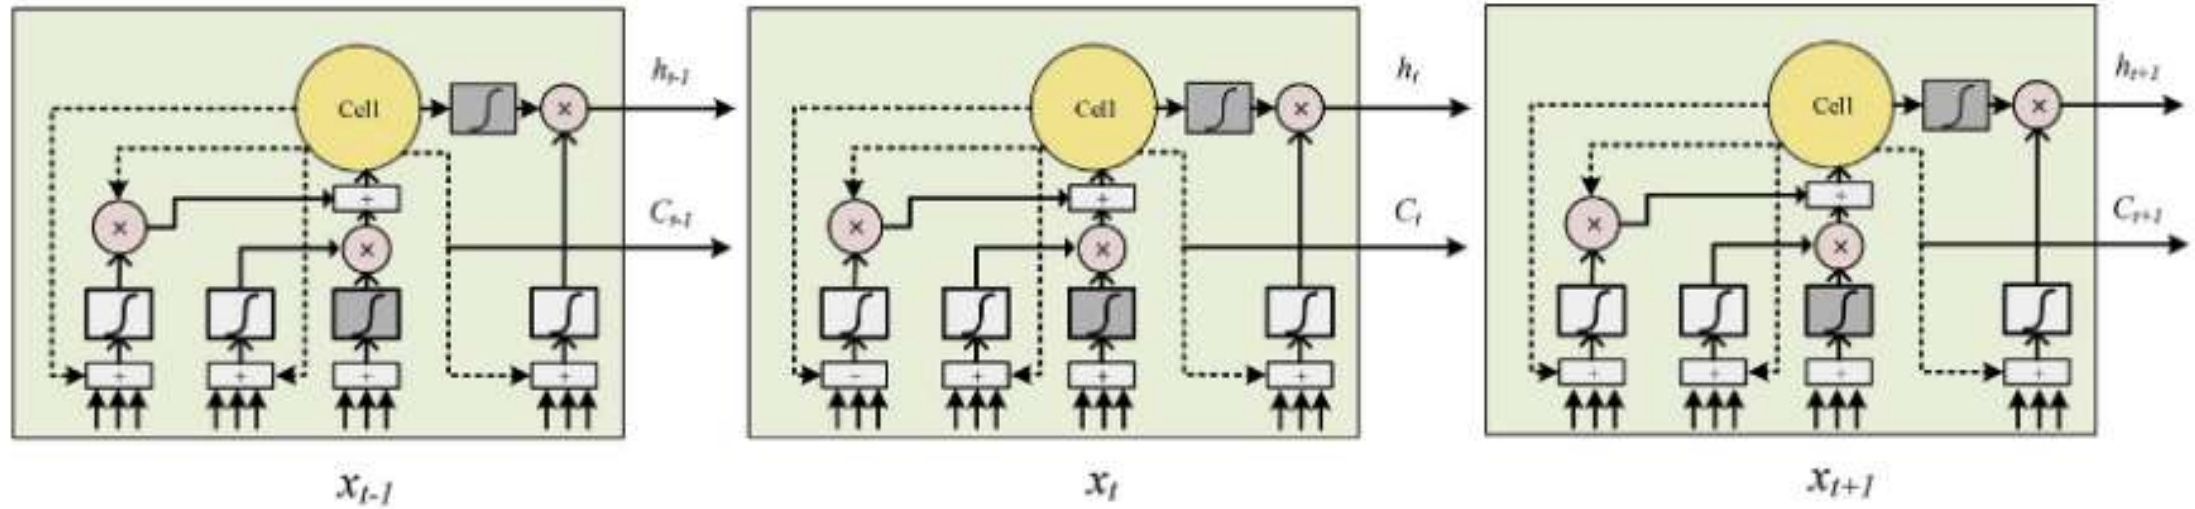
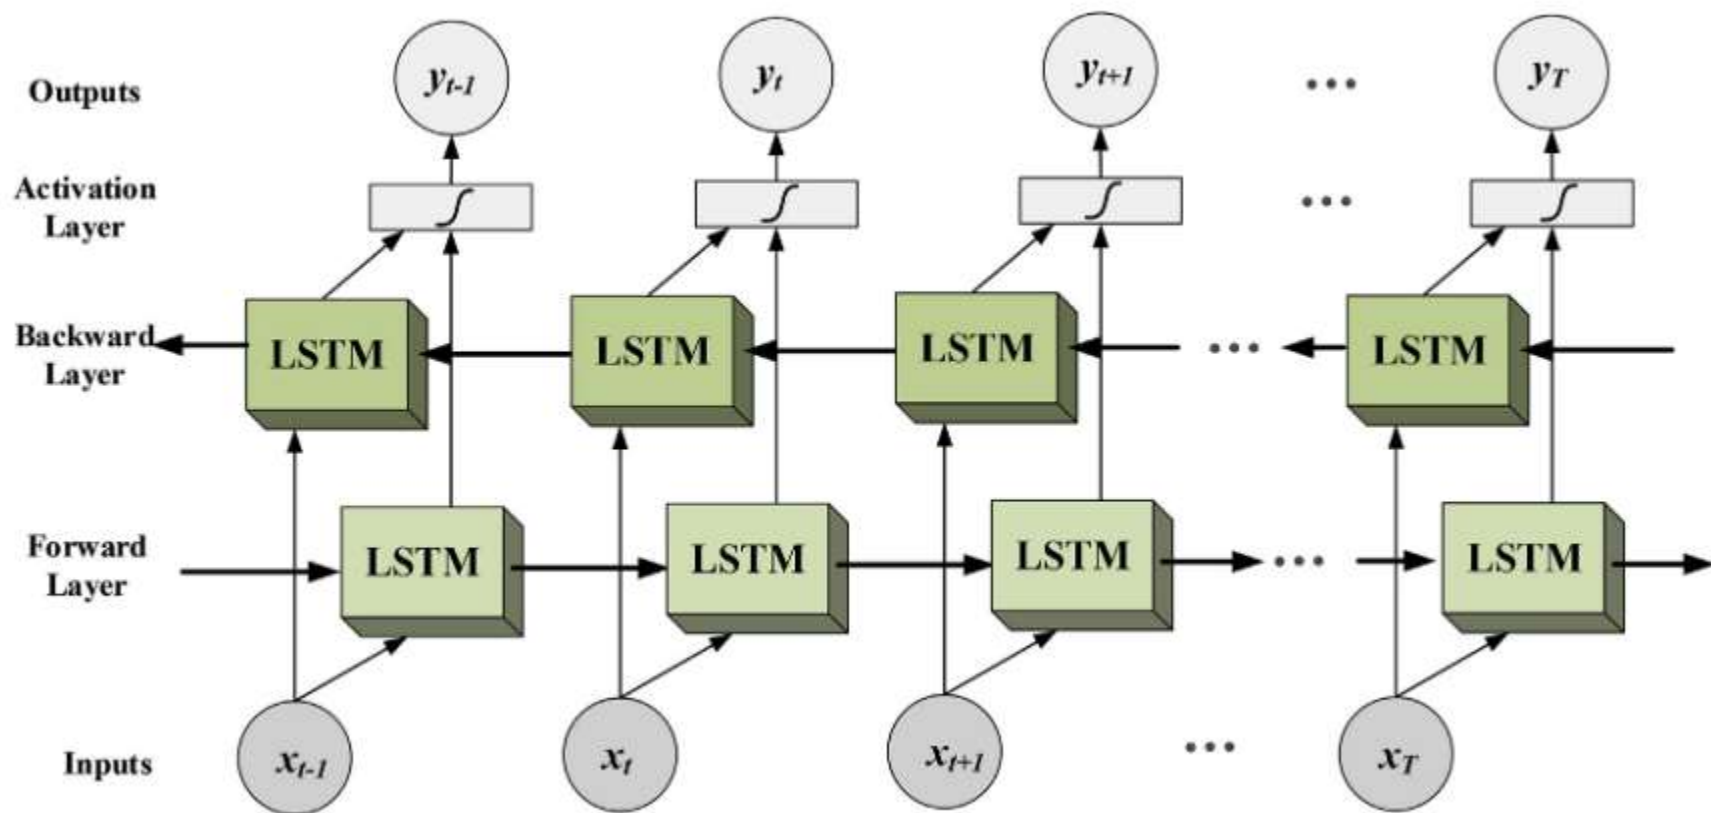


Fig. 2. Illustration of the LSTM blocks and memory cell units.

Ch.1 LSTM

双向LSTMs结构

底部的 LSTM 网络表示前向特征。上部的网络用于后向特征。两个网络都连接到一个公共激活层以产生输出



— Ch.2 Paper

1.Wavelet Sequences

2.Proposed DLSTM Networks

Ch.2 Paper


1.Wavelet Sequences

离散小波变换可以对信号进行时间尺度的分解，信号通过串联数字滤波器并推导出系数。这种分解方法也被称为多分辨率分析。


这些滤波器组分为高通（HP）和低通（LP）滤波器。

$$H = \sum_{k=-\infty}^{\infty} S[k] \varphi_h[2n - k]$$

$$L = \sum_{k=-\infty}^{\infty} S[k] \varphi_g[2n - k]$$



Ch.2 Paper- Wavelet Sequences



*输入信号 S 首先通过HP和LP滤波器，以获得第一级的细节和近似系数。

*对得到的近似系数进行滤波，得到第二能级的分量。重复此过程，直到达到指定级别，可以得到包含有关输入信号的重要信息的特征。

*细节系数表示信号与频率相关的细节属性。

*多分辨率过程中的分辨率级别取决于输入信号的大小。

例如，具有 2 个值的输入信号可以分解为 n 个电平。可以使用适当的近似值重复分解，以获得信号的较低分辨率分量。


Ch.2 Paper-LSTM

在两个网络模型的顶部，放置了一个基于小波变换的**WS-Layer**结构，应用于分段输入信号。

“**Level**”参数：如果 **Level** 参数为 3，则对信号应用 3 个级别的 **DWT**。

随后，主信号和该信号的细节系数作为序列输出。

在这个阶段，可以使用常见的小波族，例如**Daubechies**、**Bior**。



- a) DULSTM-WS 具有一个 WS 输入层、两个单向 LSTM 层和两个全连接层。
- b) DBLSTM-WS 具有一个 WS 输入层、两个双向 LSTM 和两个全连接层。

Ch.2 Paper-LSTM





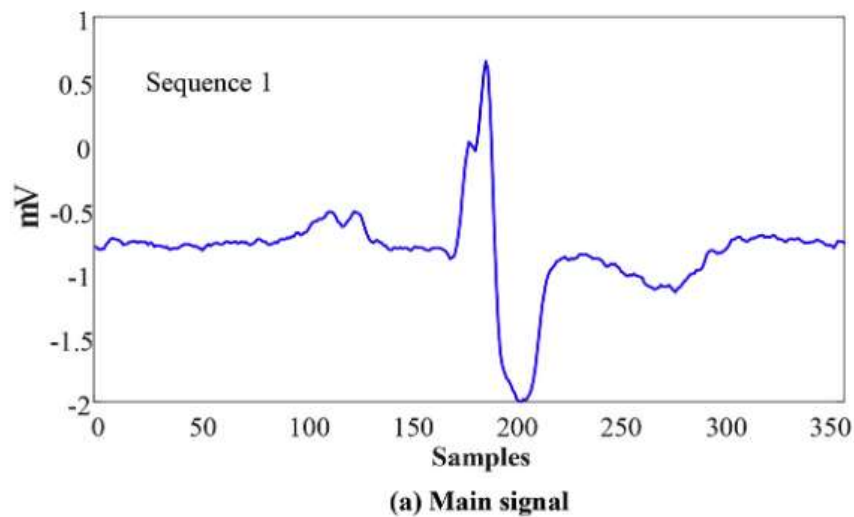
Table 1

Detailed information for each layer of the proposed network models.


Layers	Layer Names	Main Parameters of Layers	Other Parameters
Layer 1	WS Layer	4 Level	Family: Daubechies (dB6)
Layer 2	ULSTM/BLSTM	64 Unit	Returned_sequences = True, dropout = 0.1.
Layer 3	ULSTM/BLSTM	32 Unit	Returned_sequences = True, dropout = 0.1.
Layer 4	Flatten	–	–
Layer 5	Dense	128 Unit	Activation – ReLU
Layer 6	Dropout	–	Rate – 0.2
Layer 7	Dense	5 Unit	Activation – SoftMax

Ch.2 Paper-LSTM


PB(C3)类信号的WS-Layer生成的四级序列的波形




(b) 1st detail band



(c) 2nd detail band




(d) 3rd detail band



(e) 4th detail band

WS层使用主信号的细节系数，使用小波变换将子带信号转换为适合 LSTM 输入的形式。

Ch.2 Paper-LSTM



WS-Layer Output

Ch.3 Result

实验设置

Table 2
Number of training and testing ECG samples used in the experimental studies.

Class	Classification Dataset				Total
	Beat Types	Number of Training Data (60%)	Number of Validation Data (20%)	Number of Testing Data (20%)	
C1	NSR	1314	438	438	2190
C2	VPC	306	102	102	510
C3	PB	870	290	290	1450
C4	LBBB	1122	374	374	1870
C5	RBBB	813	271	272	1356
Total Data		4425	1475	1476	7376

实验数据在训练阶段分为 60%，在验证阶段分为 20%，其余 20% 在测试阶段。利用验证数据集对参数进行调优，确定所设计模型的最优单元数。


在训练模型的性能评估过程中，使用了以前未使用的测试数据。

在实验期间，各种参数设置如下：

Batch size为128，优化器为Adam优化器，损失函数为分类交叉熵。每个实验结果都是在50个 epochs内获得，以确保比较的一致性。

Ch.3 Result

Experiments on the standard DLSTMs



DULSTM网络的训练性能最高为90.54%，验证性能最高为94.85%。

DBLSTM网络的训练性能为98.92%，验证性能最高为96.81%。

当从时间成本的角度评估这些网络的性能时，DBLSTM网络每个epoch的平均持续时间为120s，而DULSTM网络平均为45s。

Ch.3 Result

Experiments on the standard DLSTMs

Confusion Matrices

Table 3

Confusion matrices of the DULSTM and DBLSTM networks on single-feature ECG signals after the 50th epoch training time.

DULSTM Network						DBLSTM Network					
Class	C1	C2	C3	C4	C5	Class	C1	C2	C3	C4	C5
C1	239	0	0	2	197	C1	244	0	0	0	194
C2	2	74	0	14	12	C2	1	87	0	12	2
C3	0	0	289	1	0	C3	0	0	289	1	0
C4	1	0	0	205	168	C4	5	1	0	282	86
C5	0	0	0	0	272	C5	0	0	0	0	272
Total success rate = 73.10%						Total success rate = 79.53%					

这两个网络都难以识别 NSR 节拍类型（C1 类）、VPC（C2 类）和 LBBB（C4 类）信号。对于 PB 和 RBBB 心跳类型（C3 和 C5 类），两种网络都提供了良好的识别。

Ch.3 Result

Experiments on the standard DLSTMs

DBLSTM网络第5层输出的学习特征的相关表

Table 4



Correlation table of learned features at the 5th layer output of the DBLSTM network according to classes.

Heartbeat Types	NSR (C1)	VPC (C2)	PB (C3)	LB BB (C4)	RB BB (C5)
NSR (C1)	1	0.6753	0.2921	0.8433	0.7406
VPC (C2)	0.6753	1	0.4247	0.7990	0.5059
PB (C3)	0.2921	0.4247	1	0.4076	−0.0035
LB BB (C4)	0.8433	0.7990	0.4076	1	0.6706
RB BB (C5)	0.7406	0.5059	−0.0035	0.6706	1

从表4中可以看出，相关值与表3中给出的混淆矩阵一致。相关性最高的类别是：C1-C4 (R 0.8433)、C2-C4 (R 0.7990) 和 C1-C5 (R 0.7406)。因此，分类器网络难以区分这些类的数据。

Ch.3 Result



Experiments on the DLSTM with a WS Layer



DULSTM-WS 网络对 ECG 信号的性能, WS 层参数的训练和验证精度从 1 到 4。

Ch.3 Result

Experiments on the DBSTM with a WS Layer



DBLSTM-WS 网络对 ECG 信号的性能, WS 层参数的训练和验证精度从 1 到 4。

Ch.3 Result

Confusion Matrices on the DULSTM-WS and DBLSTM-WS

DULSTM-WS networks performance on ECG signals with wavelet based sequences at the end of the 50th epoch.

DULSTM-WS Network (DULSTM-WS3)										
Class	C1	C2	C3	C4	C5		Precision	Recall	F1-Score	Support
C1	434	1	0	3	0	C1	1.00	0.99	0.99	438
C2	0	100	0	2	0	C2	0.99	0.98	0.99	102
C3	0	0	288	2	0	C3	1.00	0.99	1.00	290
C4	1	0	0	373	0	C4	0.98	1.00	0.99	374
C5	0	0	0	2	270	C5	1.00	0.99	1.00	272

Classification Accuracy Rate (50th epoch) = 99.25%

DBLSTM-WS Network (DBLSTM-WS2)										
C1	436	0	0	2	0	C1	0.99	1.00	0.99	438
C2	0	100	0	2	0	C2	1.00	0.98	0.99	102
C3	0	0	289	1	0	C3	1.00	1.00	1.00	290
C4	4	0	0	370	0	C4	0.99	0.99	0.99	374
C5	0	0	0	0	272	C5	1.00	1.00	1.00	272

Classification Accuracy Rate (50th epoch) = 99.39%

DBLSTM-WS2 实现了最佳识别性能，最高达到 99.50%，在第 50 个 epoch 结束时达到 99.39% 的准确率。与没有 WS 层的标准 DBLSTM 网络相比，分类性能显著提高 ($\pm 19.86\%$)。

Ch.3 Result

Experiments on the DBSTM with a WS Layer

Table 6

Correlation values among classes of features learned by the DBLSTM-WS2 network.

Heartbeat Types	NSR (C1)	VPC (C2)	PB (C3)	LBBB (C4)	RBBB (C5)
NSR (C1)	1	0.2560	0.0263	0.5746	0.2404
VPC (C2)	0.2560	1	0.2401	0.6537	0.3755
PB (C3)	0.0263	0.2401	1	0.2382	−0.0286
LBBB (C4)	0.5746	0.6537	0.2382	1	0.4638
RBBB (C5)	0.2404	0.3755	−0.0286	0.4638	1

与表 4 中给出的非 WS DULSTM 网络中学习到的特征相比，DBLSTM-WS2 类别的相关性较低。在类别 C2-C4 (R 0.6537)、C1-C4 (R 0.5746) 和 C4-C5 (R 0.4638)。

Ch.4 Summary

在研究中，设计了一个基于小波变换的新层 WS-Layer。通过这一层，使用对输入信号进行小波分解来获得后续 LSTM 网络的输入。

当评估实验结果时，可以看出所提出的 DBLSTM-WS 模型在 ECG 信号上的性能非常成功。

此外，通过端到端学习，无需额外方法即可获得与心电信号相关的显著特征，并实现直接分类。

这些结果表明，研究中提出的基于 WS 层的 DLSTM 网络模型是可用于其他信号分类系统的有效结构。

Comprehensive performance comparisons between DLSTM network models.

Deep LSTM Models	Sequences Size (samples, times, features)		Average Time (sec) Per Epoch	Accuracy Rate on Test Data
	Training	Testing		
DULSTM	$4425 \times 360 \times 1$	$1476 \times 360 \times 1$	45	73.10%
DULSTM-WS1	$4425 \times 360 \times 2$	$1476 \times 360 \times 2$	46	98.64%
DULSTM-WS2	$4425 \times 360 \times 3$	$1476 \times 360 \times 3$	49	98.37%
DULSTM-WS3	$4425 \times 360 \times 4$	$1476 \times 360 \times 4$	51	99.25%
DULSTM-WS4	$4425 \times 360 \times 5$	$1476 \times 360 \times 5$	50	98.30%
DBLSTM	$4425 \times 360 \times 1$	$1476 \times 360 \times 1$	121	79.53%
DBLSTM-WS1	$4425 \times 360 \times 2$	$1476 \times 360 \times 2$	130	98.01%
DBLSTM-WS2	$4425 \times 360 \times 3$	$1476 \times 360 \times 3$	132	99.39%
DBLSTM-WS3	$4425 \times 360 \times 4$	$1476 \times 360 \times 4$	134	98.85%
DBLSTM-WS4	$4425 \times 360 \times 5$	$1476 \times 360 \times 5$	140	98.51%

Ch.4 Summary

Table 8

Performance comparison of the proposed DBLSTM models with other state-of-the-art studies.

Study	# of Classes	# of Beats	Feature Set	Classifier	Accuracy
Osowski et al. [21]	13	12785	HOS + Herminte	SVM	98.18%
Huang et al. [23]	8	9800	ICA	SRC	98.35%
Yu and Chou [20]	8	9800	ICA	NN	98.71%
Sahoo et al. [12]	4	1071	DWT	SVM	98.39%
Elhaj et al. [16]	5	110094	PCA + DWT + HOS + ICA	SVM-RBF	98.91%
Li et al. [17]	5	100688	WPE + RR	RF	94.61%
Martis et al. [24]	5	34989	PCA	SVM-RBF	98.11%
Martis et al. [14]	5	110094	DWT + ICA	PNN	99.28%
Martis et al. [22]	5	34989	Cumulant + PCA	NN	94.52%
Ubeyli [44]	4	720	Lyapunov exponents	RNN	94.72%
Acharya et al. [46]	2	110094	End-to-end	CNN	95.22%
Acharya et al. [47]	5	109449	End-to-end	CNN	94.03%
Kiranyaz et al. [48]	5	83648	End-to-end	1D-CNN	99.00%
Zubair et al. [54]	5	100389	End-to-end	CNN	92.70%
The Proposed Study	5	7326	End-to-end	DULSTM-WS2	99.25%
	5	7326	End-to-end	DBLSTM-WS3	99.39%